

Bitácora de experimentos — camera-ready CIARP
Path Algebras of Quivers as a Sparse Multi-Hop Attention for Mitigating Over-Squashing in GNNs (envío 15, **aceptado**)

C. I. Zainea Maya A. Moreno Cañadas

Iniciada: 26 de agosto de 2026 — última actualización: 26-08-2026 (cierre de fase)

1. Contexto y observaciones de los jurados

El artículo fue **aceptado** en CIARP (Revisor 1: *accept*, puntajes 4–5 en todos los criterios; Revisor 2: *weak reject*, 3–4). Esta bitácora registra la fase experimental posterior a la aceptación y el impacto de cada resultado sobre las observaciones. Regla de trabajo: el manuscrito **no se modifica** hasta cerrar esta fase.

R1.1 Discutir el costo de precomputar A^k en grafos masivos.

R1.2 Hipotetizar un escenario concreto donde el ideal I agregue valor (p.ej. clases de caminos $\rightarrow$ cabezas de atención).

R1.3 Validar en un dataset real con over-squashing severo.

R1.4 Restaurar nombres en las referencias.

R2 “*Much of the algebraic machinery is not essential to the method*”: el modelo usaría solo el soporte de A^k como máscara dispersa; las ganancias fuertes son sintéticas; en Peptides-func empata con GAT y queda bajo los baselines afinados de la literatura.

Estrategia experimental. R2 tiene razón en que *el modelo* solo consume el soporte. La respuesta no es discutirlo sino mostrar que el álgebra hace un segundo trabajo que la máscara no puede hacer: **medir** el over-squashing y **predecir** el régimen donde Walk Attention gana. Tres frentes: (1) un índice algebraico de severidad validado contra los resultados ya publicados; (A) densificar esa curva con nuevas corridas; (B) un benchmark real elegido *por* el índice.

2. Acciones de texto ya aplicadas (commit b29769b, 26-08)

Observación	Acción	Estado
R1.4	Autores restaurados; entradas bib reales (zainea2026aiq, repos de código); DOI de CAsimulations 10.15332/23393076.11217.	[hecho]
R1.1	§4.1: precomputación por $k-1$ productos dispersos, costo por no-ceros intermedios; truncado/muestreo en grafos masivos.	[hecho]
R1.2	Trabajo futuro: grafo heterogéneo, ideal que agrupa composiciones equivalentes de relaciones tipadas $\rightarrow$ cabezas comparadas.	[hecho]
Menores	Fig. 2 al margen; Prop. 5 con $\beta/\sqrt{C}$ y valores base distintos; RINGTRANSFER acreditado a Bodnar et al. 2021; tablas ES traducidas.	[hecho]
R1.3, R2	Frentes experimentales de esta bitácora.	[en curso]

3. Experimento 1 — el índice de severidad Ψ y la curva dosis-respuesta

3.1. Derivación del índice

El argumento de capacidad del paper (Prop. 3–4) es: tras k capas de paso de mensajes, *todas* las cadenas de longitud k que entran al nodo j — una por cada elemento de la base de $\bigoplus_i e_j \mathbb{K} Q_k e_i$ — deben codificarse en un vector de ancho w . Si las cadenas fueran distinguibles y equiprobables, distinguirlas requiere $\log_2(\sum_i (A^k)_{ij})$ bits, mientras el embedding ofrece del orden de $\log_2 w$. El índice es el exceso:

$$\Psi_k(j) = \log_2\left(\sum_i (A^k)_{ij}\right) - \log_2 w, \quad \sum_i (A^k)_{ij} = \sum_i \dim_{\mathbb{K}}(e_j \mathbb{K} Q_k e_i).$$

Es álgebra graduada pura: dimensiones de las componentes $e_j \mathbb{K} Q_k e_i$ (Prop. 1 del paper), agregadas por objetivo. Es la versión por objetivo del diagnóstico por pares $H_k(i, j) = \log_2(A^k)_{ij}$ ya implementado en `aiq.gnn.over_squashing_diagnostic`. Predicción cualitativa: con $\Psi \leq 0$ el paso de mensajes tiene capacidad suficiente y la atención multi-salto no debería aportar; con $\Psi \gg 0$ el colapso es inevitable y Walk Attention (que lee las fuentes *directamente*, sin atravesar el canal comprimido) debería dominar.

3.2. Protocolo

Script `run_severity_index.py`. Para cada benchmark ya publicado se computa Ψ en *el objetivo y alcance de decisión* — el nodo que porta la etiqueta y el alcance k que la resuelve — y se cruza con la ventaja medida = media WA – mejor baseline de un salto, de los CSV por semilla de `results/tables/`:

- **Bottleneck** ($K=5$, $M=4$, $w=16$): objetivo final, $k = d+1$; masa entrante = $K \cdot M^d$, luego $\Psi = \log_2(5 \cdot 4^d) - 4$.
- **RingTransfer** ($w=32$): objetivo antipodal, $k = n/2$; el ciclo no dirigido tiene masa entrante $2^{n/2}$, luego $\Psi = n/2 - 5$.
- **Peptides-func** ($w=80$, alcances 1–4): por molécula, máximo sobre objetivos y alcances; promedio sobre las 10 873 moléculas del split de entrenamiento.

Sin ninguna corrida nueva: el experimento solo reinterpreta resultados ya publicados a la luz del índice.

3.3. Resultados

Benchmark	Ψ (bits)	alcance	WA	ventaja
ring $n=6$	-2,00	3	1.000	0.000
Peptides-func	-0,75	1-4	0.526	0.000
ring $n=10$	0,00	5	1.000	0.000
ring $n=14$	+2,00	7	1.000	+0,189
bottleneck $d=2$	+2,32	3	1.000	+0,550
ring $n=18$	+4,00	9	1.000	+0,466
bottleneck $d=3$	+4,32	4	1.000	+0,708

Spearman $\rho = 0,927$ ($p = 0,0027$); Pearson $r = 0,901$ ($p = 0,0056$); $n = 7$. Salida: `results/tables/severity_in`

3.4. Lectura

1. **Umbral, no solo tendencia.** Los tres casos con $\Psi \leq 0$ tienen ventaja *exactamente* 0,000; la ventaja aparece al cruzar $\Psi = 0$ y crece con Ψ . El corte está donde el argumento de capacidad lo pone, sin parámetros ajustados.
2. **El empate de Peptides queda predicho.** $\Psi = -0,75 < 0$: en esas moléculas ($w=80$, grado típico 2-3, alcances ≤ 4) la masa de recorridos entrante aún cabe en el embedding. El caso que R2 usa como evidencia en contra es un punto *sobre la curva* que el índice anticipa sin entrenar.
3. **Impacto sobre R2.** La “maquinaria prescindible” (las dimensiones graduadas con multiplicidad — no el patrón binario de A^k , que es el mismo para masa 2 o 22000) es la que produce Ψ . La máscara no mide; el álgebra sí.
4. **Limitación.** $n = 7$ puntos de 3 familias distintas mezcla tareas y anchos; la comparación justa es *dentro* de cada familia (monótona en ambas) y el Frente A densifica.

4. Frente A — densificación de la curva (resultados)

[completo] Lanzado 26-08 08:24, cerrado 08:55; mismo protocolo estabilizado del paper (5 semillas, AdamW, warmup, coseno, clip; LN en WA). Scripts `run_ring_fillin.py` ($n \in \{12, 16, 20\}$), `run_bottleneck_fillin.py` ($d=4$).

4.1. Resultados por configuración (media $\pm$ desv., 5 semillas)

Config.	Ψ	GCN	GAT	WA	ventaja
ring $n=12$	1,00	$0,966 \pm 0,069$	$1,000 \pm 0,000$	$1,000 \pm 0,000$	0,000
ring $n=16$	3,00	$0,532 \pm 0,274$	$0,459 \pm 0,229$	$1,000 \pm 0,000$	+0,468
ring $n=20$	5,00	$0,418 \pm 0,289$	$0,221 \pm 0,008$	$0,894 \pm 0,156$	+0,476
bottleneck $d=4$	6,32	(azar, Prop. 4)	$0,366 \pm 0,174$	$1,000 \pm 0,000$	+0,634

(En $d=4$ el operador de recorrido fijo dio $0,571 \pm 0,050$, entre GAT y WA, como en $d=2, 3$: cruza el cuello pero no selecciona.)

4.2. Contraste con las predicciones pre-registradas

Predicción (antes de correr)	Resultado
$n=12$ ($\Psi=1$): ventaja pequeña pero positiva	ventaja = 0,000 (GAT aún resuelve exacto) $\times$
$n=16$ ($\Psi=3$): ventaja entre las de $n=14$ y $n=18$	+0,468, entre +0,189 y +0,466 (borde superior) $\checkmark$
$n=20$ ($\Psi=5$): ventaja $\geq$ la de $n=18$	+0,476 vs +0,466 $\checkmark$; pero WA ya no es exacta a 10 capas (0,894; semillas {1, 1, ,82, ,65, 1}) $\checkmark \sim$
$d=4$ ($\Psi=6,32$): ventaja $\geq$ +0,7, WA = 1,000	WA = 1,000 $\checkmark$; ventaja +0,634 (GAT varió alto) $\sim$

La predicción fallida es informativa: **el umbral efectivo no está en $\Psi = 0$ sino entre $\Psi = 1$ y $\Psi = 2$** . Lectura mecánica: un bit de exceso aún puede absorberse con codificación no lineal del embedding (la cota $\log_2 w$ es conservadora); con dos o más bits el colapso es sistemático. El índice queda entonces con una zona de operación: $\Psi \leq 0$ seguro-sin-ventaja, $\Psi \geq 2$ seguro-con-ventaja, $0 < \Psi < 2$ zona de transición.

4.3. El fenómeno de transición: bimodalidad por semilla

Los promedios ocultan la estructura más reveladora. Por semilla, en $n=16$: GCN {0,61, 0,21, 0,21, 0,81, 0,82}, GAT {0,62, 0,21, 0,22, 0,80, 0,46}. Los baselines de un salto **no degradan gradualmente: o resuelven** ($\approx 0,8-1,0$) **o caen al azar** ($\approx 0,21$), y la proporción de semillas que caen crece con Ψ hasta que en $n=20/d=4$ casi todas caen. La desviación estándar por eso *sube* en la transición ($\pm 0,27$ en $n=16$; $\pm 0,17$ en $d=4$) y colapsaría a 0 en ambos extremos. Walk Attention, en cambio, da $1,000 \pm 0,000$ en **todas** las configuraciones y semillas de todos los benchmarks sintéticos — la estabilidad entre semillas es en sí misma un resultado: el soporte algebraico elimina la lotería de inicialización que decide si el canal comprimido logra o no codificar la señal.

4.4. Curva final

Con los 11 puntos: $\Psi \in \{-2, -0,75, 0, 1\} \mapsto$ ventaja 0,000; $\Psi \in \{2, 2,32, 3, 4, 4,32, 5, 6,32\} \mapsto \{+0,19, +0,55, +0,47, +0,47, +0,71, +0,48, +0,63\}$. **Spearman** $\rho = 0,875$ ($p = 4,3 \times 10^{-4}$), **Pearson** $r = 0,880$. Plana en cero hasta $\Psi = 1$, salto en $\Psi = 2$, meseta alta con ruido dominado por la bimodalidad del mejor baseline. Nota honesta: en $n=20$ (10 capas) la propia WA pierde exactitud en 2 de 5 semillas — la profundidad de la pila de atención introduce su propia dificultad de optimización, independiente del squashing.

5. Experimento 2 — cribado de redes reales con Ψ

5.1. Protocolo

Script `run_screen_real.py`. La masa entrante se computa como $\mathbf{1}^T A^k$ por iteración vector-matriz, $O(k \cdot \text{nnz})$ — sin materializar A^k : el mecanismo de escalabilidad respondido a R1.1, funcionando sobre 421K aristas en segundos. Direcciones: *as-is* (citante→citado: las cadenas de citación se acumulan en los papers citados) y *reversa*. Donde las potencias completas caben se cuenta además el sustrato del cociente: pares con $(A^k)_{ij} > 1$, i.e. $\dim(e_j \mathbb{K} Q_k e_i) > 1$ (recorridos paralelos).

5.2. Resultados (selección; tabla completa en `real_network_severity_screen.csv`)

Red	dir.	k	máx bits	frac.> $w=64$	pares paralelos	máx mult.
cit-HepPh (34 546 n.)	reversa	2	13.2	0.51	$1,1 \times 10^6$	110
	reversa	3	17.4	0.68	$9,4 \times 10^6$	1 481
	reversa	4	21.4	0.72	$3,4 \times 10^7$	22 702
Cora (2 708 n.)	reversa	6	9.5	0.22	14 711	125
	reversa	8	11.8	0.44	21 933	772
Cañadas (115 n.)	reversa	3	6.1	0.01	37	6

5.3. Lectura

- **cit-HepPh es el régimen severo real (R1.3), con margen enorme:** $\Psi \approx +15$ bits sobre $w=64$ a $k=4$; el sintético más severo del paper tiene +4,3. No es un caso construido: es la estructura natural de una red de citación con hubs.
- **La multiplicidad extrema replantea el cociente (R1.2).** El resultado negativo del paper (colapsar 2 recorridos paralelos destruye señal) se obtuvo con multiplicidades de decenas. Aquí hay pares con 22 702 cadenas paralelas: la hipótesis natural se invierte — *organizar* esas clases (cociente parcial $\rightarrow$ cabezas) debería ganar sobre ignorarlas y sobre colapsarlas. Es el experimento del espectro de ideales del Frente B.
- **Cora** es punto intermedio; **Cañadas** (leve, mult. ≤ 6) sirve como ejemplo trabajado, no como benchmark.

6. Frente B — benchmark real cit-HepPh

6.1. El problema real

Detección temprana de artículos influyentes: en 1997, con el grafo de citaciones disponible, señalar cuáles papers de 1996–97 serán los más citados en 1998–2000. El conteo de citas es un indicador retrasado; el predictor barato (apego preferencial: citas presentes predicen futuras) falla justo en los casos valiosos — los que despegan tarde. La señal correctora es estructural: *quién* te cita (¿papers que a su vez serán influyentes?) y por cuántas cadenas independientes llega tu influencia — información que vive en $e_j \mathbb{K} Q_k e_i$ con su multiplicidad, a profundidades 2–4.

6.2. Construcción del dataset (`run_hepph_dataset.py`)

Corte 31-12-1997. Grafo de contexto: 13 745 papers fechados y 98 307 citaciones entre ellos. Cohorte: 6 635 papers de 1996–97. Futuro: 51 632 citaciones recibidas en 1998–2000 (mediana 3, máximo 298). Features mínimos e idénticos para todos los modelos: año de publicación, $\log(1+\text{in})$, $\log(1+\text{out})$ al corte, estandarizados. Ids cruzados de SNAP (`11<id>`) normalizados. Severidad verificada *en el subgrafo de contexto*: máx 18,4 bits a $k=4$ ($\Psi = +12,4$ sobre $w=64$), multiplicidad máxima 4 724, $\text{nnz}(A^4) = 2,7\text{M}$.

6.3. Cinco variables objetivo

	Definición (binaria)
T1 impacto estrat.	top-cuartil de citas futuras <i>dentro</i> de su estrato de in-degree $\{0, 1-2, 3-9, 10^+\}$
T2 early riser	top-cuartil del residuo de $\log(1+c_{\text{fut}})$ sobre grado y edad
T3 amplitud	fracción de pares de citantes futuros <i>independientes</i> (sin citación mutua ni referencia compartida) sob
T4 persistencia	fracción de citas futuras tardías ($\geq$ jul-1999) sobre mediana
T5 alcance	top-cuartil del crecimiento de la 2-vecindad de impacto $ A_2(c) $

T1/T2 neutralizan el apego preferencial por construcción (estratificado / residuo). T3 es el objetivo cuya *definición* es multiplicidad de cadenas independientes — el terreno del cociente. T5 usa el grado de impacto de la tesis como variable objetivo: predecir una cantidad algebraica futura desde el álgebra presente.

6.4. Modelos y protocolo (`run_hepph_models.py`)

Transductivo sobre el grafo dirigido (citante→citado, los mensajes fluyen de citantes a citados); división estratificada 60/20/20 de la cohorte; 5 semillas; pérdida ponderada por clase; métrica: exactitud balanceada en test. Modelos: MLP (piso sin grafo), GCN, GAT (4 cabezas), Walk Attention (una capa por alcance $k = 1, 4$, soporte truncado top-32 fuentes por multiplicidad — “Scaling the support” operativo: $\text{nnz} \leq n \cdot 32$ por alcance). Todos con ancho 64 y la receta estabilizada del paper. Smoke test (3 épocas, 2 capas): mlp 0,50 / gc n 0,54 / gat 0,56 / wa 0,61 — ordenamiento alentador, no concluyente. [\[corrida completa lanzada 26-08; log en results/logs/hepph_models.log\]](#)

6.5. Hipótesis pre-registradas (antes de ver resultados)

1. En T1/T2, orden esperado $\text{MLP} < \text{GCN/GAT} < \text{WA}$; la ganancia de WA sobre GAT será mayor en los estratos de grado bajo (donde el conteo no informa y solo la estructura profunda distingue).
2. La brecha máxima WA–GAT aparecerá en **T3** (amplitud), el objetivo definido por multiplicidad de cadenas.
3. En T5 todos los modelos con grafo superarán ampliamente al MLP (el objetivo es estructural), y $\text{WA} > \text{GAT}$ por el alcance.
4. (Fase 2, espectro de cocientes sobre T3:) $I_{\text{hub}} \gtrsim I_0 \gg I_{\text{full}}$ con multiplicidad extrema — el primer resultado *positivo* del cociente.

6.6. Resultados (100 corridas base + 50 de control)

Modelo	T1	T2	T3	T4	T5
MLP (sin grafo)	0.672	0.565	0.527	0.519	0.818
GCN (sin residual)	0.636	0.548	0.542	0.522	0.744
GAT (sin residual)	0.666	0.546	0.546	0.523	0.785
GCN + residual	0.664	0.570	0.545	0.522	0.811
GAT + residual	0.673	0.584	0.550	0.529	0.810
Walk Attention	0.673	0.594	0.559	0.526	0.828

(Exactitud balanceada en test, media de 5 semillas; desviaciones 0,004–0,028. Archivo `hepph_models_5seeds.csv`.)

6.7. El confound y su control

La primera lectura (GCN/GAT *por debajo* del MLP en T1, T2, T5: “la agregación local daña”) era demasiado buena. WA lleva término residual W_{root} de fábrica; los GCN/GAT del runner no llevaban skip connections. El control (gcn_res, gat_res, mismas semillas) lo confirma: **con residual, GCN/GAT recuperan el nivel del MLP y más**; el efecto “la agregación local daña” era en su mayor parte el confound. Se descarta esa lectura.

6.8. Lo que sobrevive al control

WA sigue siendo el mejor modelo en T1 (empate), T2, T3 y T5, con ventajas pequeñas por objetivo (+0,009 a +0,018 sobre GAT+res) pero **consistentes**: prueba pareada por (objetivo, semilla), excluyendo el nulo T4 ($n = 20$ pares):

	media	pares positivos	Wilcoxon p
WA – GAT+res	+0,009	15/20	0.004
WA – GCN+res	+0,016	18/20	0.0003
WA – MLP	+0,018	16/20	0.0009

6.9. Contraste con las hipótesis y lectura revisada

- H1 (orden MLP < GCN/GAT < WA en T1/T2): ✗ en T1 (empate general: los features de grado agotan la señal); ✓ en T2 con márgenes pequeños.
- H2 (brecha máxima en T3): ✗ — la brecha máxima está en T2 (residuo ortogonal al grado), T3 segunda.
- H3 (grafo $\gg$ MLP en T5): ✗ — el grado actual predice el crecimiento de la 2-vecindad; solo WA supera al MLP, por poco.
- T4: nulo para todos.

Refinamiento del índice. $\Psi \approx +12$ predecía una ventaja *decisiva* y se observó una ventaja *pequeña y consistente*. La explicación es una distinción que el Exp. 1 no podía revelar porque sus etiquetas fueron diseñadas para depender de la información profunda: Ψ mide cuánta información de recorridos *se pierde* en el canal, no cuánta de esa información *necesita la tarea*. Es condición necesaria, no suficiente: con $\Psi \leq 1$ no hay ventaja posible (Peptides, anillos cortos); con $\Psi \gg 0$ la ventaja es posible y su magnitud la fija la dependencia del label respecto de la estructura profunda — alta en las tareas sintéticas de recuperación, modesta en la predicción de impacto con features de grado (donde el grado ya resume casi todo lo predecible). Esta es la formulación correcta para el paper.

6.10. Decisión sobre las fases 2–3

El espectro de cocientes sobre HepPh (fase 2) mediría diferencias del orden de 0,01, en el límite de resolución de 5 semillas; se pospone, salvo que se aumente a 10 semillas. I_{ring} en Peptides (fase 3) sigue siendo la pregunta abierta del paper y se mantiene en cola.

7. Cierre de fase: qué queda establecido

1. **Establecido, fuerte.** El índice Ψ y la curva dosis-respuesta (11 puntos, $\rho = 0,875$, umbral en $(1, 2]$ bits, 4 ceros exactos incluido Peptides). Responde directamente a R2: el álgebra graduada con multiplicidad predice el régimen; la máscara binaria no puede.
2. **Establecido, moderado.** En una red real de severidad extrema (cit-HepPh, $\Psi \approx +12$), WA es el mejor modelo en 4 de 5 objetivos con ventaja pequeña pero significativa ($p = 0,004$ pareado) sobre GAT con residual, con soporte truncado top-32 (escalabilidad operativa). Responde a R1.3 con honestidad: ventaja real, no dramática.
3. **Aprendido.** Ψ es necesario, no suficiente; la magnitud de la ventaja depende de cuánto el label necesita la información profunda. Y: los controles de arquitectura (residuales) son obligatorios antes de leer un “la agregación local daña”.
4. **Pendiente.** I_{ring} en Peptides; espectro de cocientes con más semillas.

Propuesta para el camera-ready (a decidir). Una subsección breve tras los experimentos: definición de Ψ (3 líneas), la curva como tabla compacta o figura, y un párrafo con cit-HepPh (T2/T3/T5 y el test pareado). Esto convierte “regime-dependent” en una predicción cuantitativa y añade el dataset real; cabe en $\sim 2/3$ de página si se comprime el ejemplo de la Sección 3.

8. Reproducibilidad

- Repositorio en b29769b (rama main) + scripts nuevos sin comprometer: `run_severity_index.py`, `run_screen_real.py`, `run_ring_fillin.py`, `run_bottleneck_fillin.py`, `run_hepph_dataset.py`, `run_hepph_models.py`.
- Salidas: `results/tables/severity_index.csv`, `real_network_severity_screen.csv`, `bottleneck_fillin_ring_transfer_fillin_5seeds.csv`, `hepph_models_5seeds.csv` (150 filas: base + control); dataset en `data/hepph/`; logs en `results/logs/`.
- Entorno: `venv oversquash` — Python 3.12.10, PyTorch 2.13.0+cpu, PyG 2.8.0.post1, NumPy 2.5.2, SciPy 1.18.1; `oversquash` y `aiq-quivers` editables.
- Datos crudos: sintéticos por semilla; Peptides-func en `data/lrgb/`; cit-HepPh/Cora/Cañadas en `../quivers_analysis/data/`.