

Álgebras de Caminos de Quivers como una Atención Dispersa Multi-Salto para Mitigar el Over-Squashing en GNNs

Autor(es) Anónimo(s)

Afiliación retenida para la revisión doble ciego

Resumen Las redes neuronales de grafos de paso de mensajes sufren de *over-squashing*: la señal que viaja por muchos caminos largos hacia un nodo se comprime en un vector de ancho fijo y se pierde. Introducimos **Walk Attention**: el *álgebra de caminos* $\mathbb{k}Q$ del quiver subyacente provee, mediante sus componentes graduadas, la estructura exacta de alcanzabilidad multi-salto, que usamos como *sopORTE* disperso de una atención aprendida—el álgebra dice qué vértices pueden interactuar a alcance k , la red aprende cuánto. En grafos de cuello de botella con over-squashing ajustable *demostramos* la separación—el paso de mensajes con agregación lineal queda exactamente en el azar para toda profundidad y todo ancho, mientras que una sola capa de Walk Attention en el alcance adecuado resuelve la tarea de recuperación exactamente—y la confirmamos empíricamente ($1,000 \pm 0,000$ sobre cinco semillas, donde la atención de un salto se degrada hacia el azar); Walk Attention se mantiene exacta en RINGTRANSFER y, bajo un presupuesto pequeño compartido, empata con la atención de un salto en Peptides-func: su ventaja es decisiva bajo over-squashing severo y modesta cuando es leve. Un resultado negativo afina el diseño: colapsar caminos equivalentes vía el cociente $\mathbb{k}Q/I$ descarta multiplicidad que la tarea necesita; el papel del álgebra es *definir el soporte*, no comprimir.

Keywords: Redes neuronales de grafos · Over-squashing · Álgebra de caminos · Quiver · Teoría de representaciones · Atención.

1. Introducción

Las redes neuronales de grafos construidas sobre el paradigma de paso de mensajes [13] actualizan cada nodo agregando mensajes de sus vecinos inmediatos e iterando esta regla local a través de las capas, de modo que tras k capas la información de nodos a k saltos alcanza un nodo objetivo. Aunque simple y efectivo, el esquema tiene un modo de fallo bien documentado: el *over-squashing* [3]. Cuando el número de caminos que llevan información hacia un nodo crece—típicamente de forma exponencial con la distancia—los mensajes a lo largo de todos ellos deben comprimirse en un único vector de ancho fijo; el nodo receptor no puede recuperarlos individualmente y la señal de largo alcance se pierde. El over-squashing es el obstáculo principal para tareas cuyas etiquetas dependen

de información distante o distribuida globalmente. Los remedios existentes actúan sobre el grafo o sobre la agregación: el *rewiring* ensancha los cuellos de botella [20], los análisis de curvatura y sensibilidad explican *dónde* ocurre [9], y una línea complementaria reemplaza la agregación local por atención global de Transformer [21], a costo cuadrático y ciego a la estructura del grafo.

En este artículo tomamos una ruta diferente, fundamentada en la teoría de representaciones de quivers. Un *quiver* es un grafo dirigido, posiblemente con flechas múltiples [18, 7], y su *álgebra de caminos* $\mathbb{k}Q$ tiene como base los recorridos dirigidos del quiver, con la concatenación como multiplicación. La pieza graduada $e_j \cdot \mathbb{k}Q_k \cdot e_i$ de esta álgebra tiene como base los recorridos dirigidos de longitud k del vértice i al vértice j ; su dimensión es $(A^k)_{ij}$, la entrada correspondiente de la k -ésima potencia de la matriz de adyacencia. El álgebra de caminos provee, por tanto, una *descripción exacta y algebraica de la alcanzabilidad y la multiplicidad multi-salto*.

Nuestra observación central es que esta estructura es precisamente lo que se necesita para definir una atención multi-salto dispersa con fundamento. Dejamos que cada nodo atienda directamente a todo vértice alcanzable desde él por un recorrido de longitud k : el álgebra provee el *soporte* de la atención (qué pares pueden interactuar a alcance k), y la red aprende los *pesos* (cuánto). Como el soporte es disperso—típicamente una pequeña fracción de todos los pares—esto es mucho más barato que la auto-atención completa, sin dejar de actuar a distancia, evitando el cuello de botella iterativo. Llamamos a la arquitectura resultante **Walk Attention**. Como una red de grafos sobre Q es una representación del quiver $(\text{Rep}(Q) \cong \mathbb{k}Q\text{-Mod})$, Walk Attention es la lectura *aprendida* de un sustrato algebraico cuya lectura *dinámica* es el marco de autómatas de impacto sobre quivers [4] (Sección 3.6).

Contribuciones.

1. Una construcción autocontenida (Sección 3) de quivers, álgebras de caminos, el sistema de vecindades por grado de impacto y los *operadores de recorrido* que codifican la alcanzabilidad multi-salto, con ejemplos desarrollados.
2. **Walk Attention** (Sección 4): una atención multi-salto aprendida cuyo soporte es la alcanzabilidad del álgebra de caminos, relacionada con el paso de mensajes y con los Transformers.
3. Una separación *demostrada* (Sección 4.2): con la profundidad estándar de una capa por salto, toda GNN cuya primera agregación es lineal en los atributos de las fuentes (GCN, GIN) tiene precisión exactamente igual al azar en la familia de cuellos de botella, para toda profundidad, ancho y parámetros, mientras que una sola capa de Walk Attention en el alcance adecuado resuelve la tarea exactamente—confirmado empíricamente (Sección 5).
4. Un resultado *negativo* que afina el diseño: colapsar caminos equivalentes vía el cociente $\mathbb{k}Q/I$ descarta multiplicidad necesaria y falla; el papel del cociente es determinar el soporte, no comprimir la señal.

2. Trabajo Relacionado

Over-squashing, atención y agregación multi-salto. Alon y Yahav [3] identificaron el over-squashing con la prueba NEIGHBORMATCH; Topping et al. [20] lo conectaron con la curvatura negativa y propusieron el rewiring SDRF; Di Giovanni et al. [9] dieron un análisis de sensibilidad. GAT [22] aprende pesos de atención de un salto; los graph Transformers aplican atención de todos los pares [21] a costo $O(n^2)$. Agregar más allá de un salto está, en sí, bien explorado: MixHop [2] y SIGN [11] mezclan potencias fijas de la adyacencia, la convolución por difusión [12] recablea con un núcleo de difusión, MAGNA [23] difunde los puntajes de atención, el paso de mensajes por caminos más cortos agrega sobre capas de distancia [1], NAGphormer [8] tokeniza agregados por salto, Graphormer [24] sesga la atención densa por la distancia más corta, y DRew [14] recablea dinámicamente con retardo. Walk Attention difiere en el objeto que define el soporte: el *álgebra de caminos graduada*—recorridos con su multiplicidad, no capas de distancia ni pesos de difusión—lo que hace el soporte exacto (Proposición 1), expone el cociente $\mathbb{k}Q/I$ como grado de libertad de diseño e inserta la arquitectura en la teoría de representaciones de quivers.

Estructura algebraica de caminos. El álgebra de caminos es un objeto estándar de la teoría de representaciones [18,7]; las álgebras de configuración de Brauer y construcciones afines se han aplicado recientemente a problemas combinatorios [17,16]. Lo más cercano al presente trabajo es el sistema de vecindades por grado de impacto y el marco de autómatas de impacto [4,15], que tomamos como el hermano dinámico de Walk Attention sobre el mismo sustrato (Sección 3.6). La atención sobre soportes multi-salto no es nueva en sí misma; lo nuevo, hasta donde sabemos, es tomar el soporte del álgebra de caminos graduada, con sus multiplicidades, su cociente y su lectura dinámica.

3. El Álgebra de Caminos de un Quiver

Esta sección es autocontenida: construimos los quivers, los caminos, el álgebra de caminos con su graduación, el sistema de vecindades por grado de impacto y los operadores de recorrido en que se apoya el modelo de la Sección 4, sin suponer exposición previa. Referencias estándar: [18,7].

3.1. Quivers y caminos

Definition 1. *Un quiver es una cuádrupla $Q = (Q_0, Q_1, s, t)$ donde Q_0 es un conjunto finito de vértices, Q_1 un conjunto finito de flechas y $s, t: Q_1 \rightarrow Q_0$ asignan a cada flecha α su fuente $s(\alpha)$ y su destino $t(\alpha)$; escribimos $\alpha: i \rightarrow j$. Se permiten flechas múltiples entre el mismo par ordenado. Identificamos Q_0 con $\{1, \dots, n\}$.*

Un quiver es así un multigrafo dirigido, el dato de una estructura relacional dirigida: entidades, relaciones dirigidas y flechas paralelas que registran multiplicidad.

Example 1. Sea $Q_0 = \{1, 2, 3\}$ con flechas $\alpha, \alpha': 1 \rightarrow 2$ (dos flechas paralelas), $\beta: 2 \rightarrow 3$ y un lazo $\gamma: 3 \rightarrow 3$. Su matriz de adyacencia, contando flechas, es

$$A = \begin{pmatrix} 0 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix}.$$

En una red de citaciones, por ejemplo, los vértices son documentos, las flechas citaciones, el par paralelo α, α' una citación doble y el lazo γ una autocitación.

Definition 2. Un camino de longitud $k \geq 1$ en Q es una secuencia de flechas $p = \alpha_k \cdots \alpha_2 \alpha_1$ con $t(\alpha_r) = s(\alpha_{r+1})$, leída de derecha a izquierda como la composición de funciones, con fuente $s(p) = s(\alpha_1)$ y destino $t(p) = t(\alpha_k)$. Cada vértice i porta además un camino trivial e_i de longitud 0.

Un camino es un *recorrido* dirigido: vértices y flechas pueden repetirse. En el Ejemplo 1, $\beta\alpha$ y $\beta\alpha'$ son dos caminos distintos de longitud 2 de 1 a 3, y el lazo genera recorridos arbitrariamente largos $\gamma^m\beta\alpha$. El número de recorridos distintos de una longitud dada entre dos vértices es precisamente la cantidad que produce el over-squashing, y el álgebra de caminos lo hace algebraicamente explícito.

3.2. El álgebra de caminos y su graduación

Sea $\mathbb{k}$ un cuerpo (en la práctica $\mathbb{k} = \mathbb{R}$).

Definition 3. El álgebra de caminos $\mathbb{k}Q$ es el $\mathbb{k}$ -espacio vectorial con base el conjunto de todos los caminos de Q , dotado de la multiplicación bilineal dada en la base por la concatenación:

$$q \cdot p = \begin{cases} qp & \text{si } s(q) = t(p), \\ 0 & \text{en otro caso.} \end{cases}$$

Los caminos triviales satisfacen $e_{t(p)}p = p = pe_{s(p)}$ y $e_ie_j = \delta_{ij}e_i$, de modo que $\{e_i\}$ es un sistema completo de idempotentes ortogonales y $1 = \sum_i e_i$ es la unidad.

La multiplicación respeta la longitud: concatenar caminos de longitudes k y ℓ da un camino de longitud $k + \ell$ (o cero). Por tanto $\mathbb{k}Q$ es una álgebra *graduada*,

$$\mathbb{k}Q = \bigoplus_{k \geq 0} \mathbb{k}Q_k, \quad \mathbb{k}Q_k \cdot \mathbb{k}Q_\ell \subseteq \mathbb{k}Q_{k+\ell},$$

con $\mathbb{k}Q_k$ generada por los caminos de longitud exactamente k ; en particular $\mathbb{k}Q_0 = \bigoplus_i \mathbb{k}e_i$ y $\mathbb{k}Q_1$ está generada por las flechas. Los idempotentes permiten aislar los caminos entre un par fijo de vértices: el subespacio $e_j \cdot \mathbb{k}Q_k \cdot e_i$ está generado exactamente por los caminos de longitud k de i a j , y su dimensión es por tanto el número de tales recorridos. La siguiente proposición, en la que se apoya todo lo que el modelo calcula, hace precisa la correspondencia con el álgebra lineal.




Figura 1. El quiver diamante del Ejemplo 2: dos recorridos paralelos de longitud 2, $1 \rightsquigarrow 4$; $\dim(e_4 \mathbb{k} Q_2 e_1) = 2$.

Proposition 1. Sea $A \in \mathbb{N}^{n \times n}$ la matriz de adyacencia de Q , $A_{ij} = \#\{\alpha \in Q_1 : \alpha : i \rightarrow j\}$. Entonces, para todo $k \geq 0$ y todos $i, j \in Q_0$,

$$\dim_{\mathbb{k}}(e_j \cdot \mathbb{k} Q_k \cdot e_i) = (A^k)_{ij}.$$

Demostración. Inducción sobre k ; para $k \in \{0, 1\}$ es la definición. Todo camino de longitud k de i a j se factoriza de forma única como $\alpha \cdot p$, con p de longitud $k-1$ de i a algún vértice intermedio r y $\alpha : r \rightarrow j$ una flecha; el número de tales factorizaciones es $\sum_r (A^{k-1})_{ir} A_{rj} = (A^k)_{ij}$. $\square$

Llamamos a $n_k(i, j) := (A^k)_{ij} = \dim_{\mathbb{k}}(e_j \mathbb{k} Q_k e_i)$ la *multiplicidad de recorrido* de i a j a alcance k . Es exactamente el número de mensajes de longitud k que una GNN de paso de mensajes fuerza del nodo i hacia el nodo j tras k capas—y por tanto la fuente del over-squashing.

Example 2. Sea Q con vértices $\{1, 2, 3, 4\}$ y flechas $\alpha_1 : 1 \rightarrow 2$, $\alpha_2 : 1 \rightarrow 3$, $\beta_1 : 2 \rightarrow 4$, $\beta_2 : 3 \rightarrow 4$ (Figura 1). Entonces

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}, \quad A^2 = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix},$$

y $\dim(e_4 \mathbb{k} Q_2 e_1) = (A^2)_{14} = 2$, de acuerdo con la Proposición 1: los dos recorridos *paralelos* de longitud 2, $\beta_1 \alpha_1$ y $\beta_2 \alpha_2$, con la misma fuente, el mismo destino y la misma longitud. Si deben tratarse como un canal o como dos es una decisión de modelado a la que volvemos en la Sección 5.

3.3. Grado de impacto y el sistema fundamental de vecindades

La graduación por longitud induce una estratificación canónica de los vértices alrededor de cada nodo, que organiza la estructura multi-salto que el modelo explotará. El *grado de impacto* $g(i, j)$ es la longitud del camino dirigido más corto de i a j (con $g(i, i) = 0$ y $g(i, j) = \infty$ si no existe); equivalentemente, $g(i, j) = \min\{k : (A^k)_{ij} > 0\}$, el primer alcance en que la multiplicidad se hace positiva.

Definition 4. Para un nodo $c \in Q_0$, su vecindad de entrada de radio k es $A_k(c) = \{i \in Q_0 : g(i, c) \leq k\}$, el conjunto de nodos que pueden influir en c por un camino dirigido de longitud a lo sumo k . La familia anidada $\{A_k(c)\}_{k \geq 0}$, con $A_0(c) = \{c\} \subseteq A_1(c) \subseteq \dots$, es el sistema fundamental de vecindades (SFV) de c ; la capa $\mathcal{N}_k(c) = A_k(c) \setminus A_{k-1}(c)$ reúne los nodos a grado de impacto exactamente k .

El SFV es el objeto combinatorio sobre el que actúan los operadores de recorrido de más abajo, y su relación precisa con la alcanzabilidad es la siguiente.

Proposition 2. Para $k \geq 1$ sea $\mathcal{S}_k = \{(c, i) : (A^k)_{ic} > 0\}$ el conjunto de pares unidos por un recorrido de longitud k , $i \rightsquigarrow c$. Entonces

$$\{(c, i) : i \in \mathcal{N}_k(c)\} \subseteq \mathcal{S}_k,$$

y la inclusión es estricta en general: los recorridos de longitud k pueden alcanzar también nodos a grado de impacto $< k$. Si Q es graduado—existe $\rho: Q_0 \rightarrow \mathbb{Z}$ con $\rho(t(\alpha)) = \rho(s(\alpha)) + 1$ para toda flecha α —vale la igualdad para todo k .

Demostración. Si $g(i, c) = k$, un camino más corto es un recorrido de longitud k , así que $(A^k)_{ic} > 0$. Estrictez: en $1 \rightarrow 2 \rightarrow 3$ con una flecha adicional $1 \rightarrow 3$, $(A^2)_{13} > 0$ y sin embargo $g(1, 3) = 1$. Si Q es graduado, todo recorrido $i \rightsquigarrow c$ tiene longitud $\rho(c) - \rho(i)$, así que un recorrido de longitud k fuerza $g(i, c) = k$. $\square$

Los grafos del benchmark de la Sección 5 son graduados (el índice de capa es un tal ρ), así que allí los soportes coinciden con las capas del SFV; en grafos con ciclos, como un anillo, $\mathcal{S}_k$ contiene estrictamente la relación de capas. La multiplicidad $n_k(i, c)$ registra cuántos caminos de longitud k pueblan cada capa—el refinamiento algebraico del grado de impacto escalar.

3.4. Operadores de recorrido

La Proposición 1 permite convertir el álgebra graduada en una familia de operadores lineales sobre los atributos, uno por alcance; son el puente hacia el modelo neuronal.

Definition 5. Para cada alcance $k \geq 1$ defínase $W^{(k)} \in \mathbb{R}^{n \times n}$ por

$$W_{ji}^{(k)} = \frac{(A^k)_{ij}}{Z_k}, \quad Z_k = \max_j \sum_i (A^k)_{ij},$$

una sola constante de normalización por alcance. El soporte de alcanzabilidad por recorridos es $\mathcal{S}_k = \{(j, i) : (A^k)_{ij} > 0\}$.

Actuando sobre una matriz de atributos $H \in \mathbb{R}^{n \times d}$, el operador $W^{(k)}H$ envía a cada nodo j una suma ponderada de los atributos de cada nodo i que lo alcanza por un recorrido de longitud k , con peso proporcional a la multiplicidad

$n_k(i, j)$. Dos hechos merecen énfasis. (i) *Normalización global, no por filas*: normalizar por filas mapearía las multiplicidades a una distribución uniforme sobre las fuentes alcanzables, borrando exactamente la información que distingue a $W^{(k)}$ de una simple máscara de alcanzabilidad; la constante global preserva las multiplicidades relativas acotando las magnitudes. (ii) *Sparsity*: $\mathcal{S}_k$ es el patrón de no-ceros de A^k , así que en los grafos de interés $W^{(k)}$ se almacena y aplica en $O(|\mathcal{S}_k|)$ y no en $O(n^2)$. El operador de pesos fijos $W^{(k)}$ ya mitiga el over-squashing, porque deja que el nodo j lea las fuentes a alcance k *directamente*, en un paso, en vez de forzar la señal por k rondas locales. Su limitación—que motiva Walk Attention—es que sus pesos están fijados por la multiplicidad y no pueden *seleccionar* qué fuente importa.

3.5. El álgebra cociente

La teoría de representaciones pasa rutinariamente de $\mathbb{k}Q$ a un cociente $\mathbb{k}Q/I$ por un *ideal admisible* I , identificando caminos declarados iguales. En el diamante del Ejemplo 2, la relación $\beta_1\alpha_1 \equiv \beta_2\alpha_2$ genera un ideal con $\dim(e_4(\mathbb{k}Q/I)_2e_1) = 1$: los dos recorridos paralelos colapsan a una sola clase, y en general $\dim(e_j(\mathbb{k}Q/I)_ke_i) \leq n_k(i, j)$. Es tentador usarlo como remedio del over-squashing: reemplazar las multiplicidades por las dimensiones menores, deduplicando caminos antes de agregar. Lo probamos y resultó *contraproducente* (Sección 5): colapsar recorridos paralelos destruye información de multiplicidad que las tareas pueden requerir. El papel constructivo del cociente no es comprimir la señal sino *remodelar el soporte*—por ejemplo enrutando clases de caminos distintas a cabezas de atención distintas, dirección que dejamos a trabajo futuro. En el modelo que sigue el álgebra entra solo por el soporte $\mathcal{S}_k$ y los operadores sin cociente $W^{(k)}$.

3.6. Un suelo algebraico común

Los objetos anteriores—el álgebra graduada $\mathbb{k}Q$, el grado de impacto con su SFV y el cociente $\mathbb{k}Q/I$ —forman un sustrato algebraico que se especializa en dos direcciones, según cómo se lea un mapa de actualización φ sobre las capas $\mathcal{N}_k(c)$. En la lectura *dinámica*, φ es una regla de evolución fija ponderada por el grado de impacto; iterarla en el tiempo da los *autómatas de impacto sobre quivers* (AIQ), con sus reglas SI/SIS/SIR y su estructura categórica, desarrollados aparte [4,15]. En la lectura *representacional*, tomada aquí, φ se *aprende*: un espacio vectorial por vértice y un mapa lineal por flecha es una representación de Q (un $\mathbb{k}Q$ -módulo, vía $\text{Rep}(Q) \cong \mathbb{k}Q\text{-Mod}$), y una GNN sobre Q es tal representación con mapas aprendidos. Walk Attention es su instancia graduada.

4. Walk Attention

Definimos ahora la arquitectura, y empezamos por la observación que la motiva: *el operador de recorrido ya es una atención*. Una capa de atención, en su forma general, fija una relación de *soporte* S de pares (objetivo, fuente) y

calcula, para cada objetivo j , una combinación ponderada y normalizada de atributos transformados de las fuentes,

$$\text{out}_j = \sum_{i: (j,i) \in S} \alpha_{ji} Vx_i, \quad \alpha_{ji} \geq 0, \quad \sum_i \alpha_{ji} \text{ acotada}, \quad (1)$$

y las arquitecturas difieren solo en dos elecciones: *qué pares* contiene S y *de dónde salen los coeficientes* α . La auto-atención de los Transformers [21] toma $S =$ todos los pares y aprende α de productos consulta-clave; GAT [22] toma $S =$ las aristas y aprende α . Compárese ahora con el operador de la Definición 5: actuando sobre atributos calcula $(W^{(k)}H)_j = \sum_{i: (j,i) \in \mathcal{S}_k} \frac{n_k(i,j)}{Z_k} H_i$ —*exactamente la forma* (1), con soporte la alcanzabilidad $\mathcal{S}_k$ y coeficientes fijados en las multiplicidades normalizadas. Agregar sobre recorridos de longitud k no es, pues, “parecido” a una atención: *es* una atención cuyo soporte el álgebra de caminos determina exactamente (Proposición 1) y cuyos pesos están congelados. Esto dicta el diseño: conservar el soporte algebraico y reemplazar los pesos congelados de multiplicidad por pesos consulta-clave aprendidos—el resultado es Walk Attention, la actualización aprendida φ del sustrato común de la Sección 3.6.

4.1. La capa de Walk Attention

Fijemos un alcance k con soporte $\mathcal{S}_k$. Una capa de Walk Attention con H cabezas de dimensión C calcula consultas, claves y valores con mapas lineales, $Q^h = xW_Q^h$, $K^h = xW_K^h$, $V^h = xW_V^h$, y atiende *solo sobre los pares alcanzables* $(j, i) \in \mathcal{S}_k$:

$$\ell_{ji}^h = \frac{1}{\sqrt{C}} \langle Q_j^h, K_i^h \rangle, \quad \alpha_{ji}^h = \text{softmax}_{i: (j,i) \in \mathcal{S}_k} \ell_{ji}^h, \quad z_j^h = \sum_{i: (j,i) \in \mathcal{S}_k} \alpha_{ji}^h V_i^h. \quad (2)$$

El softmax se toma, para cada objetivo j , exactamente sobre las fuentes que lo alcanzan por un recorrido de longitud k —un softmax *segmentado* sobre el soporte, nunca sobre los n nodos. Las salidas de las cabezas se concatenan y se añade un término “raíz” residual, $\text{WA}_k(x)_j = \|_h z_j^h + x_j W_{\text{root}}$. Como (2) solo toca pares de $\mathcal{S}_k$, la capa cuesta $O(|\mathcal{S}_k|HC)$ en tiempo y memoria, no $O(n^2)$; los soportes se precaculan una vez por grafo como los patrones de no-ceros de A^k . La Figura 2 muestra el flujo de datos y el Algoritmo 1 resume una capa.

Example 3. En el diamante del Ejemplo 2 a alcance $k = 2$ el soporte es el único par $\mathcal{S}_2 = \{(4, 1)\}$: el nodo 4 atiende directamente al nodo 1, el softmax sobre un singulete da $\alpha_{41} = 1$, y $\text{WA}_2(x)_4 = Vx_1 + x_4 W_{\text{root}}$ —los dos recorridos paralelos se vuelven una interacción *directa*. Si se añade una segunda fuente $1'$ con flechas hacia 2 y 3, el soporte pasa a $\mathcal{S}_2 = \{(4, 1), (4, 1')\}$: el softmax pondera ahora las dos fuentes por el ajuste de sus claves con la consulta Qx_4 , de modo que el nodo 4 lee ambas fuentes a alcance 2 directamente y *elige entre ellas*—mientras que una red de un salto debe empujar ambas señales por los vértices compartidos 2, 3: la compresión misma que el over-squashing nombra.




Figura 2. Una capa de Walk Attention a alcance k . Consultas, claves y valores son mapas lineales de los atributos; la atención se calcula *solo* sobre los pares alcanzables S_k que provee el álgebra de caminos (el patrón de no-ceros de A^k), se agrega y se suma un término raíz residual. La caja verde del soporte distingue a Walk Attention de la atención densa (todos los pares) y de la de un salto (aristas).

Algorithm 1 Capa de Walk Attention a alcance k (dispersa).

Require: atributos $x \in \mathbb{R}^{n \times d_{\text{in}}}$; soporte $S_k = \{(j, i) : (A^k)_{ij} > 0\}$

- 1: $Q, K, V \leftarrow xW_Q, xW_K, xW_V$ ▷ por cabeza; formas $n \times HC$
- 2: **for** cada $(j, i) \in S_k$ y cabeza h **do**
- 3: $\ell_{ji}^h \leftarrow \langle Q_j^h, K_i^h \rangle / \sqrt{C}$
- 4: **end for**
- 5: $\alpha_{ji}^h \leftarrow \text{softmax segmentado sobre } \{i : (j, i) \in S_k\}$
- 6: $z_j^h \leftarrow \sum_i \alpha_{ji}^h V_i^h$ ▷ scatter-add hacia los objetivos
- 7: **return** $\|_h z^h + xW_{\text{root}}$

Una red de Walk Attention de profundidad L apila una capa por alcance $k = 1, \dots, L$, de modo que capas sucesivas leen recorridos progresivamente más largos; cada capa va seguida de normalización de capa, una no linealidad ELU y dropout, y un MLP final mapea la incrustación a las salidas. La normalización de capa importa en la práctica: sin ella la atención aprendida tiene alta varianza entre inicializaciones; con ella, junto a un warmup corto y recorte de gradiente, el entrenamiento converge de forma confiable (Sección 5).

La Tabla 1 sitúa a Walk Attention entre los operadores relacionados según los dos ejes de (1): GAT aprende pesos pero propaga por L capas apiladas—el régimen del over-squashing; un graph Transformer paga $O(n^2)$ y descarta la estructura; el operador de recorrido tiene el soporte correcto pero no selecciona. Walk Attention ocupa la celda restante.

4.2. Un tratamiento formal sobre la familia de cuellos de botella

Sobre la familia de cadenas con cuello de botella de la Sección 5, la separación entre el paso de mensajes de un salto y Walk Attention se puede *demostrar*, no solo medir. La construcción: K fuentes llevan una *clave* one-hot—la asignación

Cuadro 1. Walk Attention frente a operadores de agregación relacionados, según los dos ejes de (1): soporte y pesos.

Operador	Soporte	Pesos	Costo
GCN / paso de mensajes	1 salto	fijos (grado)	$O(Q_1)$
Atención sobre grafos (GAT)	1 salto	aprendidos	$O(Q_1)$
Operador de recorrido $W^{(k)}$	alcanzable por recorridos	fijos (multiplicidad)	$O(S_k)$
Transformer de grafo	todos los pares	aprendidos	$O(n^2)$
Walk Attention (nuestra)	alcanzable por recorridos	aprendidos	$O(S_k)$

de claves es una permutación aleatoria uniforme π —y un *valor* one-hot; siguen d capas de cuello de botella $L_1, \dots, L_d$ de M vértices intercambiables y sin atributos, con capas consecutivas totalmente conectadas; un objetivo lleva una *consulta* one-hot q y debe producir el valor de la fuente cuya clave es q (etiqueta $\pi^{-1}(q)$, azar $1/K$). Las redes tienen la profundidad estándar $L = d + 1$ (una capa por salto, como en [3]) y ancho oculto w .

Proposition 3. *Para toda red de paso de mensajes cuya actualización $h'_v = U(h_v, \text{AGG}\{h_u : u \rightarrow v\})$ se comparte entre vértices: tras cada ronda, los M vértices de cada capa de cuello de botella llevan estados idénticos. Por tanto toda la influencia de las fuentes sobre el objetivo pasa por un único estado w -dimensional por capa—mientras que KM^d recorridos la transportan (Proposición 1).*

Demostración. Inducción sobre la ronda: los vértices de una capa empiezan iguales (atributos cero) y comparten su multiconjunto de entrada (todas las fuentes para L_1 , todo L_{r-1} para L_r), así que U y AGG compartidos los mantienen iguales. $\square$

Proposition 4. *Si además los mensajes son lineales en el estado del emisor con coeficientes independientes del contenido—como en GCN y GIN—entonces, con $L = d + 1$ capas, la salida del objetivo depende de las fuentes solo a través de $\sum_s x_s$, que es la misma para toda π : las claves one-hot de una permutación suman el vector de unos. La precisión esperada es exactamente $1/K$ para todo d, w y parámetros.*

Demostración. La información de las fuentes que entra a L_1 en la ronda t necesita d saltos más, llegando al objetivo en la ronda $t+d \leq d+1$ solo si $t \leq 1$; en la ronda 1 el mensaje de la fuente s es un mapa lineal fijo del atributo crudo x_s con un coeficiente compartido (las fuentes son isomorfas en el grafo), así que el estado de L_1 es función de $\sum_s x_s$, cuyos bloques de clave y de valor son independientes de π . Dada q , la etiqueta $\pi^{-1}(q)$ es uniforme, así que toda predicción independiente de π acierta $1/K$. $\square$

Proposition 5. *A alcance $k = d + 1$ el soporte del objetivo es exactamente las K fuentes (el grafo es graduado; Proposición 2). Con W_Q proyectando la casilla de consulta escalada por cualquier $\beta > 0$, W_K la casilla de clave, W_V la casilla de*

valor y $W_{root} = 0$, la salida $z_t = \sum_s \alpha_s e_{v(s)}$ de una sola capa de Walk Attention tiene su mayor entrada en el valor correcto, en toda instancia, para todos d y M .

Demostración. El logit de la fuente s es $\beta \mathbf{1}[\pi(s) = q]$, así que el softmax pone su mayor peso $e^\beta / (e^\beta + K - 1)$ en la única coincidencia s^* ; siendo los valores vectores distintos de la base, la mayor coordenada de z_t es α_{s^*} , en $v(s^*) = \pi^{-1}(q)$. $\square$

Example 4. Tómese $K = 2$, $M = 2$, $d = 1$ y profundidad $L = 2$. Las dos asignaciones de claves, $\pi = \text{id}$ y el intercambio, producen la *misma* suma de fuentes $\sum_s x_s$ (bloques de clave y de valor ambos $(1, 1)$), así que por la Proposición 4 una GCN o GIN calcula salidas idénticas en las dos instancias—cuyas etiquetas difieren: precisión $1/2$, azar. Una capa de Walk Attention a alcance 2 atiende sobre $\{s_1, s_2\}$ con logits $\beta \langle e_q, e_{\pi(s)} \rangle$, que distinguen las instancias desde la primera multiplicación y seleccionan la fuente coincidente (Proposición 5).

Remark 1. Las proposiciones delimitan los mecanismos observados en la Sección 5. GAT escapa a la Proposición 4—sus coeficientes de la primera ronda dependen del contenido—pero debe hacer pasar la asociación clave–valor por el canal de un solo vector de la Proposición 3, re-codificado $d + 1$ veces: queda por encima del azar y se degrada con la profundidad. El operador de pesos fijos lee las fuentes directamente pero con pesos *iguales* (todas las multiplicidades valen M^d), así que debe incrustar el multiconjunto completo en w dimensiones en vez de seleccionar: se estanca entre ambos. Walk Attention lee directamente y selecciona (Proposición 5), y resuelve la tarea.

5. Experimentos

Evaluamos sobre una familia controlada con over-squashing severo y ajustable, y luego sobre dos benchmarks externos. Todo el código, las configuraciones y los registros se publican [6].

Recuperación en cadena con cuello de botella. Instanciamos la familia de la Sección 4.2 con $K=5$, $M=4$ y profundidades $d \in \{2, 3\}$: la multiplicidad hacia el objetivo es KM^d (Proposición 1), mientras que el soporte más profundo consta solo de los K pares fuente–objetivo ($5/196 \approx 2,6\%$ de los pares a $d=2$, $5/324 \approx 1,5\%$ a $d=3$). Todos los modelos usan ancho 16, cuatro cabezas cuando corresponde, $d+1$ capas/alcances y AdamW con warmup de diez épocas, decaimiento coseno y recorte de gradiente; Walk Attention añade normalización de capa. Reportamos precisión de validación en el objetivo (la tarea sintética no tiene partición de prueba separada), media $\pm$ desviación sobre cinco semillas. La Tabla 2 cae exactamente donde las Proposiciones 3–5 la sitúan (Observación 1): GCN y GIN quedan clavados en el azar y allí se quedan empíricamente; GAT se degrada abruptamente con la profundidad; el operador de recorrido cruza el cuello en un paso pero no puede seleccionar la fuente coincidente y se estanca; **Walk Attention resuelve la tarea exactamente** en ambas profundidades

Cuadro 2. Precisión en el objetivo (media $\pm$ desv. sobre 5 semillas) en la recuperación con cuello de botella, $K=5$, $M=4$; azar $1/K = 0,20$; la respuesta está a $d+1$ saltos. GCN/GIN quedan en el azar como exige la Proposición 4 (el residuo es sesgo de mejor época).

Model	depth $d = 2$	depth $d = 3$
GCN (one-hop, linear aggregation)	$0,21 \pm 0,01$	$0,22 \pm 0,01$
GIN (one-hop, linear aggregation)	$0,21 \pm 0,01$	$0,21 \pm 0,01$
GAT (one-hop attention)	$0,45 \pm 0,22$	$0,29 \pm 0,17$
Walk operator (fixed weights)	$0,62 \pm 0,12$	$0,50 \pm 0,12$
Walk Attention (ours)	$1,000 \pm 0,000$	$1,000 \pm 0,000$

Cuadro 3. Precisión en RINGTRANSFER frente al tamaño n (distancia $n/2$), media $\pm$ desv. sobre 5 semillas; azar 0,20.

Model	$n=6$	$n=10$	$n=14$	$n=18$
GCN	$1,00 \pm 0,00$	$1,00 \pm 0,00$	$0,81 \pm 0,13$	$0,53 \pm 0,33$
GAT	$1,00 \pm 0,00$	$1,00 \pm 0,00$	$0,69 \pm 0,29$	$0,29 \pm 0,19$
Walk Attention (ours)	$1,00 \pm 0,00$	$1,00 \pm 0,00$	$1,00 \pm 0,00$	$1,00 \pm 0,00$

y todas las semillas. Sin normalización de capa ni warmup su precisión osciló entre 0,44 y 1,00 según la semilla; los estabilizadores eliminan la varianza por completo—un artefacto de optimización, no una propiedad del operador.

RingTransfer. Para confirmar el efecto en un benchmark independiente usamos RINGTRANSFER [9]: un ciclo de n nodos donde una fuente debe transmitir su etiqueta one-hot (cinco clases, azar 0,2) al objetivo diametralmente opuesto, a $n/2$ saltos por los *dos arcos* del anillo. Cada nodo tiene dos vecinos, así que el número de recorridos de longitud $n/2$ que entran al objetivo—lo que una red de un salto debe comprimir tras $n/2$ capas—crece como $2^{n/2}$, mientras solo los dos arcos portan la señal. Todos los modelos usan ancho 32, la misma receta de optimización y $n/2$ capas/alcances. La Tabla 3 reporta los resultados: los anillos pequeños son fáciles para todos; desde $n=14$ (distancia 7) las líneas base de un salto se degradan y se vuelven muy dependientes de la semilla—en $n=18$ GAT cae a $0,29 \pm 0,19$ y GCN a $0,53 \pm 0,33$ —mientras **Walk Attention se mantiene en $1,000 \pm 0,000$** . La brecha se amplía con el tamaño del anillo, esto es, con la severidad del over-squashing, como se predijo.

Colapsar recorridos perjudica. El cociente $\mathbb{k}Q/I$ de la Sección 3 sugiere un remedio alternativo: reemplazar las multiplicidades $n_k(i, j)$ por las dimensiones menores del cociente, deduplicando recorridos equivalentes antes de agregar. Comparamos ambos operadores en una ablación que cambia *únicamente* el operador, con datos, arquitectura y receta de la Tabla 2 fijos. La Tabla 4 muestra al cociente claramente por debajo del operador crudo en ambas profundidades: colapsar recorridos paralelos descarta la multiplicidad de fuentes que la recupe-

Cuadro 4. Deduplicar recorridos vía $\mathbb{K}Q/I$ *perjudica*: media $\pm$ desv. sobre 5 semillas, mismo protocolo de la Tabla 2 (la fila del operador coincide).

Operator	depth $d = 2$	depth $d = 3$
Quotient $\mathbb{K}Q/I$ (collapsed walks)	$0,39 \pm 0,04$	$0,30 \pm 0,09$
Walk operator (raw walks)	$0,62 \pm 0,12$	$0,50 \pm 0,12$

Cuadro 5. LRGB Peptides-func, AP de prueba (media $\pm$ desv. sobre 4 semillas), presupuesto pequeño compartido que aísla el operador; los resultados publicados bajo el protocolo estándar de 500k son mayores para toda arquitectura [10,19].

Model	test AP
GCN	$0,492 \pm 0,011$
GAT	$0,526 \pm 0,004$
Walk Attention (ours)	$0,526 \pm 0,007$

ración necesita. En este régimen los caminos redundantes son *señal*, no ruido; la contribución del álgebra es el soporte, no la compresión. Si existe un régimen donde la compresión del cociente ayude—camino paralelos genuinamente redundantes, o clases de caminos enrutadas a cabezas distintas—queda abierto.

LRGB Peptides-func. Para evaluar con datos reales usamos Peptides-func [10] (10,873/2,331/2,331 grafos moleculares, mediana 138 nodos; clasificación multi-etiqueta, Average Precision de prueba), con el mismo embedding de átomos, cuatro capas, ancho 80, pooling de media y AdamW para todos los modelos; Walk Attention usa alcances $k = 1, \dots, 4$, cuyo soporte sigue disperso (1–8 % de n^2 a alcance 3). Tabla 5: Walk Attention supera a GCN y es estadísticamente indistinguible de GAT ($0,526 \pm 0,007$ frente a $0,526 \pm 0,004$ sobre cuatro semillas). Dos salvedades enmarcan la comparación. Primera, todos los modelos comparten un presupuesto deliberadamente pequeño, así que los números absolutos quedan por debajo de los publicados (GCN 0,593 bajo el protocolo afinado de 500k parámetros [10], mayores aún en re-evaluaciones [19]): la comparación es *interna*, aislando el operador de agregación. Segunda, el empate no se debe a la ausencia de caminos paralelos (los péptidos contienen cientos de pares unidos por varios recorridos cortos) sino a que el over-squashing es *leve* en estos grafos pequeños. La ventaja del soporte multi-salto es por tanto *dependiente del régimen*: decisiva cuando el squashing es severo (Tablas 2–3), modesta cuando es leve, a alrededor de $1,6\times$ el tiempo de pared de GAT—muy por debajo de la atención densa.

6. Conclusión y Trabajo Futuro

Introducimos Walk Attention, una arquitectura que mitiga el over-squashing atendiendo sobre un soporte multi-salto provisto por el álgebra de caminos del

quiver subyacente. La Proposición 1 da el soporte y sus multiplicidades exactamente; las Proposiciones 3–5 demuestran la separación en la familia de cuellos de botella—el paso de mensajes con primera agregación lineal queda en el azar para toda profundidad y ancho, mientras una capa de Walk Attention en el alcance adecuado es exacta—y los experimentos la confirman, con ventaja dependiente del régimen en RINGTRANSFER y Peptides-func. Un resultado negativo complementario mostró que comprimir recorridos equivalentes vía el cociente es contraproducente cuando la multiplicidad porta señal: el papel del álgebra es determinar el soporte de la atención, no descartar información. La construcción es deliberadamente elemental y autocontenida, una puerta de entrada de la teoría de representaciones de quivers al aprendizaje de representaciones en grafos; es la lectura aprendida de un sustrato común cuya lectura dinámica es el marco AIQ [4]. Siguen varias direcciones.

- **De los pesos aprendidos a la dinámica.** Inyectar los pesos de atención aprendidos en un AIQ como regla de evolución guiada por datos, y recíprocamente dejar que los análisis de estabilidad del AIQ interpreten lo aprendido—para nosotros el puente más prometedor.
- **Benchmarks con over-squashing severo.** Tareas reales de largo alcance con cuellos de botella agudos, comparadas contra rewiring [20], métodos multi-salto [14] y graph Transformers.
- **Soportes con forma de cociente.** Usar $\mathbb{k}Q/I$ para *particionar* los recorridos en clases enrutadas a cabezas de atención distintas, en lugar de comprimir; identificar qué relaciones I sirven, y aprenderlas de los datos, es un problema atractivo.
- **Escalar el soporte.** Truncar, muestrear o aprender soportes admisibles más dispersos en grafos densos, donde el soporte de alcance k puede crecer.

Reproducibilidad. Los generadores de grafos, los operadores de recorrido, la capa Walk Attention, las líneas base y los registros de experimentos se publican [6]; los cálculos del álgebra usan una biblioteca abierta de álgebras de caminos [5].

Referencias

1. Abboud, R., Dimitrov, R., Ceylan, İ.İ.: Shortest path networks for graph property prediction. In: Learning on Graphs Conference (LoG) (2022)
2. Abu-El-Haija, S., Perozzi, B., Kapoor, A., Alipourfard, N., Lerman, K., Harutyunyan, H., Ver Steeg, G., Galstyan, A.: MixHop: Higher-order graph convolutional architectures via sparsified neighborhood mixing. In: International Conference on Machine Learning (ICML) (2019)
3. Alon, U., Yahav, E.: On the bottleneck of graph neural networks and its practical implications. In: International Conference on Learning Representations (ICLR) (2021)
4. Anonymous: Automata of impact over quivers (2026), manuscript in preparation; reference withheld for double-blind review

5. Anonymous: A Python library for quivers, path algebras, and impact automata (2026), version 1.2.1; anonymous repository, link released upon acceptance
6. Anonymous: Walk attention — code and experiments (2026), anonymous repository; link released upon acceptance
7. Assem, I., Simson, D., Skowroński, A.: Elements of the Representation Theory of Associative Algebras: Volume 1. Cambridge University Press (2006)
8. Chen, J., Gao, K., Li, G., He, K.: NAGphormer: A tokenized graph transformer for node classification in large graphs. In: International Conference on Learning Representations (ICLR) (2023)
9. Di Giovanni, F., Giusti, L., Barbero, F., Luise, G., Lio, P., Bronstein, M.M.: On over-squashing in message passing neural networks: The impact of width, depth, and topology. In: Proceedings of the 40th International Conference on Machine Learning (ICML). PMLR, vol. 202, pp. 7865–7885 (2023)
10. Dwivedi, V.P., Rampášek, L., Galkin, M., Parviz, A., Wolf, G., Luu, A.T., Beaini, D.: Long range graph benchmark. In: Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track. vol. 35 (2022)
11. Frasca, F., Rossi, E., Eynard, D., Chamberlain, B., Bronstein, M., Monti, F.: SIGN: Scalable inception graph neural networks. arXiv preprint arXiv:2004.11198 (2020)
12. Gasteiger, J., Weissenberger, S., Günnemann, S.: Diffusion improves graph learning. In: Advances in Neural Information Processing Systems (NeurIPS) (2019)
13. Gilmer, J., Schoenholz, S.S., Riley, P.F., Vinyals, O., Dahl, G.E.: Neural message passing for quantum chemistry. In: Proceedings of the 34th International Conference on Machine Learning (ICML). PMLR, vol. 70, pp. 1263–1272 (2017)
14. Gutteridge, B., Dong, X., Bronstein, M.M., Di Giovanni, F.: DRew: Dynamically rewired message passing with delay. In: International Conference on Machine Learning (ICML) (2023)
15. Ibáñez Huertas, J.A., Zainea Maya, C.I.: CAsimulations: Modelado de la dinámica topológica en una enfermedad mediante autómatas celulares. *Comunicaciones en Estadística* **18**(1) (2025). <https://doi.org/10.15332>
16. Moreno Cañadas, A., Rodríguez-Nieto, J.G., Salazar Díaz, O.P.: Brauer configuration algebras induced by integer partitions and their applications in the theory of branched coverings. *Mathematics* **12**(22), 3626 (2024). <https://doi.org/10.3390/math12223626>
17. Osorio Angarita, M.A., Moreno Cañadas, A.: Brauer configuration algebras for multimedia based cryptography and security applications. *Multimedia Tools and Applications* **80**(15), 23485–23510 (2021). <https://doi.org/10.1007/s11042-020-10239-3>
18. Schiffler, R.: Quiver Representations. Springer (2014)
19. Tönshoff, J., Ritzert, M., Rosenbluth, E., Grohe, M.: Where did the gap go? Reassessing the long-range graph benchmark. *Transactions on Machine Learning Research* (2024), arXiv:2309.00367
20. Topping, J., Di Giovanni, F., Chamberlain, B.P., Dong, X., Bronstein, M.M.: Understanding over-squashing and bottlenecks on graphs via curvature. In: International Conference on Learning Representations (ICLR) (2022)
21. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. In: Advances in Neural Information Processing Systems (NeurIPS). vol. 30 (2017)
22. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Lio, P., Bengio, Y.: Graph attention networks. arXiv preprint arXiv:1710.10903 (2017)
23. Wang, G., Ying, R., Huang, J., Leskovec, J.: Multi-hop attention graph neural networks. In: International Joint Conference on Artificial Intelligence (IJCAI) (2021)

24. Ying, C., Cai, T., Luo, S., Zheng, S., Ke, G., He, D., Shen, Y., Liu, T.Y.: Do transformers really perform badly for graph representation? In: Advances in Neural Information Processing Systems (NeurIPS) (2021)